

WESTFÄLISCHE WILHELMS-UNIVERSITÄT MÜNSTER

PRAKTIKUM ZUR MUSTERERKENNUNG

Emotionserkennung

Klassifikation von Action Units anhand von Landmarks

Robin Rexeisen

Matrikelnr. 123456

Johannes Stricker

johannesstricker@gmx.net

Matrikelnr. 383779

Alexander Schlüter

alx.schlueter@gmail.com

Matrikelnr. 409649

Betreuer:

Sören Klemm

soeren.klemm@wwu.de

eingereicht am 16. September 2016



FACHBEREICH 10
MATHEMATIK UND
INFORMATIK

Vorwort

Hier entsteht ein Vorwort.

Inhaltsverzeichnis

1. Einleitung	1
1.1. Facial Action Code	1
1.2. DISFA Datenbank	1
1.3. Die Aufgabenstellung	1
2. Methodik	2
2.1. Ground-Truth Daten	2
2.2. Vorverarbeitung	2
2.2.1. Aufbereitung der Eingabedaten	2
2.2.2. Feature Extraction	3
2.3. Evaluierungsmethoden	6
3. Implementierung	8
3.1. QViewer	8
3.2. Auto-Train	8
4. Ergebnis	10
5. Diskussion	13
6. Fazit	16
6.1. Zusammenfassung	16
6.2. Ausblick	16
A. Anhang	17
A.1. Auflistung der relevanten Action Units	17

1. Einleitung

Das Thema der (visuellen) Emotionserkennung durch Computersysteme hat in den letzten Jahren immer mehr an Bedeutung gewonnen. Die Einsatzgebiete sind vielseitig und reichen von Sicherheitsanwendungen, über Robotik, bis hin zu Unterhaltungsmedien. Meist wird versucht, anhand von verschiedenen Merkmalen im Gesicht, diesem eine oder mehrere Emotionen zuzuordnen. Im Rahmen unsere Praktikums, war es unsere Aufgabe ein solches Computersystem zur Erkennung von Emotionen zu entwickeln.

Im folgenden Kapitel werden die Aufgabenstellung, sowie die Eingabedaten genauer beschrieben. In Kapitel 2 werden daraufhin die Methodiken vorgestellt, die wir für unser Programm nutzen, woraufhin in Kapitel 3 erläutert wird, wie wir diese implementiert haben. Daraufhin folgt die Vorstellung unserer Ergebnisse in Kapitel 4, die wir anschließend in Kapitel 5 diskutieren. Im letzten und 6. Kapitel wird das Ergebnis der Arbeit kurz resümiert.

1.1. Facial Action Code

Der Facial Action Code (kurz FAC) ist ein System zur Unterscheidung von Bewegungen von isolierten Teilen des menschlichen Gesichts, welches 1976 von Paul Ekman und Wallace V. Friesen entwickelt wurde. Es basiert auf sogenannten Action Units (kurz AU), welche eben genau diese Bewegungen beschreiben sollen. Dabei kann eine Action Unit eine Ausprägung zwischen einschließlich 0 und 5 haben, wobei 0 bedeutet, dass keine entsprechende Bewegung vorhanden ist, und 5 bedeutet, dass die Bewegung maximal stark ausgeprägt ist [ekman]. Eine Auflistung der für diese Arbeit relevanten Action Units findet sich im Anhang A.1.

1.2. DISFA Datenbank

Die Denver Intensity of Spontaneous Facial Action Database (kurz DISFA Database) enthält eine Sammlung von Gesichtsbewegungen von insgesamt 27 unterschiedlichen, erwachsenen Probanden. Hierzu wurde von jedem Probanden ein 4-minütiges Video mit je 20 Frames pro Sekunde gedreht. Danach wurde jedes Frame nach dem Facial Action Coding System auf die Ausprägung von 12 Action Units analysiert und gelabelled. Weiterhin enthält jedes Frame 66 Landmark Koordinaten, von markanten Punkten des Gesichtes.

1.3. Die Aufgabenstellung

Die Aufgabenstellung des Praktikums bestand darin, aus einer Auswahl von 10 Videos der DISFA Datenbank einen Klassifikator zu entwickeln, der möglichst präzise in der Lage ist für ein beliebiges Frame aus der Datenbank zu bestimmen, welche Action Units in dem Frame aktiviert sind.

2. Methodik

In diesem Kapitel werden sowohl die von uns verwendeten Methoden zum Training der Klassifikatoren und zum Klassifizieren, als auch die von uns verwendeten Klassifikatoren selbst genauer beschrieben. Außerdem wird erläutert, wie die Ergebnisse evaluiert wurden.

2.1. Ground-Truth Daten

Wie zuvor erwähnt, besitzt eine Action Unit eine Ausprägung I zwischen 0 und 5. Um die spätere Klassifikation zu erleichtern wollen wir das Problem vereinfachen, indem wir nur in zwei Kategorien klassifizieren: „Aktiv“ und „nicht Aktiv“. Dazu setzen wir ein Schwellenwert $0 < h \leq 5$ ein. Falls $I < h$, so gehen wir von keiner Aktivierung aus. Falls $h \leq I$, so wollen wir davon ausgehen, dass die Action Unit aktiv ist gegeben hat.

2.2. Vorverarbeitung

2.2.1. Aufbereitung der Eingabedaten

Wie bereits in der Einleitung erwähnt, handelt es sich bei den Eingabedaten um 12 Videos, die der DISFA Datenbank entnommen sind. Die Videos wurden nacheinander aufgenommen und zeigen verschiedene Probanden. Bedingt dadurch, sind die Landmarks in den Videos nicht identisch bezüglich Skalierung, Rotation und Position.

Damit die Klassifikation durch diese Störungen nicht beeinträchtigt wird, werden die Eingabedaten zunächst normalisiert. Dies geschieht in drei Schritten.

1. Die Landmarks werden um den Koordinaten-Ursprung zentriert. Hierzu berechnen wir einen Vektor vom Mittelpunkt aller Landmarks zum Ursprung und translatieren die gesamte Punktwolke um diesen Vektor.
2. Daraufhin wird die Punktwolke so skaliert, dass die maximale horizontale Distanz alle Landmarks genau 1 beträgt. Hierzu berechnen wir diese maximale Distanz und teilen alle Koordinaten der Landmarks durch diese.
3. Um Störungen durch Drehung des Kopfes der Probanden auszugleichen, normalisieren wir ebenfalls die Rotation der Punktwolke. Dazu berechnen wir einen Vektor zwischen den beiden Augen des Probanden und rotieren die gesamte Punktwolke so, dass dieser Vektor auf eine Rotation von 0° gebracht wird (siehe Abbildung 2.1)

Ein weiteres Problem der Eingabedaten besteht darin, dass die Relation von true-positives zu true-negatives sehr gering ist, das heißt die Anzahl der Frames in denen eine bestimmte Action Unit aktiv ist, ist für die meisten Action Units relativ gesehen sehr gering.

Um dieses Problem zu reduzieren, ermöglichen wir es die true-positives der Eingabedaten zu erweitern, indem die entsprechenden Frames dupliziert und die Landmarks in diesen Frames durch eine leichte, normalverteilte Störung verschoben werden.




Abbildung 2.1.: Normalisierung der Rotation durch einen Vektor zwischen den Augen des Probanden

2.2.2. Feature Extraction

Bei der (visuellen) Emotionserkennung wird versucht anhand von einem oder mehreren, verschiedenen Merkmalen (engl. Features) einem Gesicht eine oder mehrere Emotionen zuzuordnen. Je mehr Aussagekraft die Kombination dieser Merkmale über die jeweiligen Emotionen haben, desto besser können diese klassifiziert werden. Das Problem dabei ist, dass meist weder die Merkmale, noch ihre Aussagekraft zuvor bekannt sind. Deshalb extrahieren wir aus den Eingabedaten, also den Videos mit je 66 Landmarks pro Frame, verschiedene Merkmale, um sie in verschiedenen Kombinationen miteinander zu testen. Es folgt eine Beschreibung der von uns verwendeten Features. Die Methode, wie diese erzeugt werden, werden wir im Folgenden als Feature-Extraction bezeichnen.

Statische Features

Mit statischen Features bezeichnen wir solche, die mit Hilfe der Landmarks von genau einer Frame erzeugt werden.

1. **X-/Y-Koordinaten (XY):** die Koordinaten der Landmarks werden als Merkmale genutzt. Da in der Menge der Koordinaten sowohl Informationen über die individuellen Punkte liegen, als auch Informationen über ihre Relation zueinander, ist es sinnvoll dieses Feature zu testen.
2. **Paarweise Orientierung:** es werden jeweils alle Paare von je zwei unterschiedlichen Landmarks betrachtet und die Rotation des Vektors zwischen den beiden Punkten als Merkmal genutzt. Weil sich bei verschiedenen Mimiken meist die Position markanter Punkte im Gesicht zueinander ändert, erscheint es sinnvoll Features zu nutzen, die die Landmarks untereinander explizit in Relation setzen.
3. **Paarweise Euklidische Distanz (EuclidianDist.):** auch hier werden jeweils alle Paare unterschiedlicher Landmarks betrachtet und die euklidische Distanz zwischen den beiden Punkten als Merkmal benutzt. Dieses Feature erscheint ebenfalls sinnvoll, weil es Informationen über die Relation von Landmarks untereinander hat.
4. **Orientierung relativ zum Mittelpunkt der Landmarks (Orientation):** bei diesem Feature wird die Orientierung jedes Landmarks relativ zum Mittelpunkt aller Landmarks betrachtet, das heißt es wird die Rotation des Vektors zwischen Mittelpunkt und Landmarks als Merkmal genutzt. Dieses Feature enthält Informationen darüber, wie die Position der Landmarks relativ zum gesamten Gesicht ist. Dies erscheint für viele Gesichtsausdrücke sinnvoll.
5. **Euklidische Distanz zum Mittelpunkt der Landmarks (CenterDist.):** dieses Feature betrachtet die euklidische Distanz jedes Landmarks zum Mittelpunkt aller Landmarks. Dieses Feature sagt ebenfalls etwas über die Relation der einzelnen Landmarks zum gesamten Gesicht aus.




Abbildung 2.2.: InterpolationFeatureExtraction




Abbildung 2.3.: TimeDifferentialExtraction

6. **Polynominterpolation (Interpolation):** hierbei werden verschiedene Bereiche der Gesichts einzeln betrachtet (z.B. die Oberlippe, siehe Abbildung 2.2). Diese Landmarks werden zuerst normiert. Dazu verschiebt man die dortigen Punkte, so dass der Mittelpunkt der Koordinaten-Ursprung ist. Danach werden sie so skaliert, dass die maximale Entfernung in x -Richtung gleich 1 ist. Nach dieser Normierung werden diese Punkte durch ein Polynom interpoliert. Hierzu wird die Methode der kleinsten Quadrate angewendet. Die dadurch berechnete Koeffizienten des Polynoms werden nun verwendet. Sie ergeben nämlich mit den Polynomkoeffizienten der anderen Gesichtsbereiche die Features. Dieses Verfahren hat folgende Vorteile: Erstens fließt ein eventuelles Rauschen durch Interpolation anhand mehrerer Punkte weniger in die resultierende Feature mit ein. Und zweitens wird der Feature-Raum verringert, da mehrere Punkte durch wenige Koeffizienten repräsentiert werden.

Zeitliche Features

Bisher haben wir den zeitlichen Aspekt bei der Berechnung der Features außer Acht gelassen. Die oben aufgelisteten statischen Features werden nur anhand einer Frame berechnet. Man kann jedoch eine statische Featureberechnung um einen zeitlichen Aspekt erweitern, indem wir ihre Veränderung über die Zeit als Feature benutzen. Um die zeitliche Ableitung zu einem bestimmten Zeitpunkt zu berechnen, wird numerisch Differentiation benutzt. Es bezeichne $t \in \mathbb{N}$ den aktuellen Zeitpunkt und $f(t) \in \mathbb{R}^d$, $d \in \mathbb{N} \setminus \{0\}$ den Feature-Vektor eines statischen Features. Nun ergibt sich das zeitliche Feature durch die numerische Ableitung $\frac{f(t+\delta) - f(t-\delta)}{2}$. Üblicherweise nimmt man $\delta = 1$ an, doch da sich eventuell ein aussagekräftigeres Resultat ergibt, wenn man einen größeren zeitlichen Abstand benutzt, wollen wir hier $\delta \in \mathbb{N} \setminus \{0\}$ beliebig voraussetzen.

Als Beispiel nehmen wir die zeitliche Ableitung der X-/Y-Koordinaten (siehe dazu Abbildung 2.3). Hier werden zum Zeitpunkt $t + 1$ und $t - 1$ die Koordinaten voneinander subtrahiert und halbiert. Zum Beispiel $\Delta v_{43} := \frac{v_{43}(t+1) - v_{43}(t-1)}{2} \in \mathbb{R}^2$ (wobei $v_j(t)$ die Koordinate des Punktes $j \in \{0, \dots, 65\}$ zum Zeitpunkt t ist). Diese sich so ergebende Differenz dient nun als neues Feature.

Nun können jedoch nicht mehr die Intensität der Action Units direkt als Vorlage für eine aktive oder nicht aktive Action benutzt werden. Um das zu veranschaulichen gehen wir von einem Zeitraum aus, an den sich eine Action aktiv ist, aber ihre Intensität nicht ändert. Da keine Änderung passiert, wird sich auch in den errechneten Features kaum was ändern. Die zeitliche Ableitung wird also nahe 0 sein, soll aber als

aktiv klassifiziert werden. Die Ableitung ist aber auch nahe 0, wenn sich kaum was ändert und die Action nicht aktiv ist. Um dieses Problem zu lösen, betrachtet man ebenfalls die zeitliche Differenz der Intensität der Action Unit. Wir subtrahieren hierfür die Intensität zum Zeitpunkt $t + 1$ und $t - 1$. Falls die absolute zeitliche Differenz einen Schwellenwert überschreitet, gehen wir von einer aktiven Action aus, sonst von einer nicht aktiven. Somit bezeichnen wir nun nur das Abklingen bzw. Aufkommen einer Action Unit als „Aktiv“.

Featureverarbeitung

Mit den bis hierher extrahierten Features wäre es möglich einen Klassifikator zu trainieren. Dies kann jedoch effizienter geschehen, wenn die Features zuvor noch einmal vorverarbeitet werden. Wir haben die Features folgendermaßen verarbeitet:

- **Reduktion der true-negatives:** Aus der Natur der Eingabedaten ergibt sich, dass das Verhältnis von true-positives zu true-negatives sehr gering ist, das heisst über die Gesamtheit der Frames ist eine ActionUnit in der Regel nur in sehr wenigen Frames aktiviert. Dies kann dazu führen, dass der Klassifikator Mühe hat diese zu erkennen. Um dem Problem entgegenzuwirken können einige der true-negative Frames (das heisst sowohl die Einträge über die ActionUnit, als auch die zum Frame extrahierten Features) entfernt und so das Verhältnis von true-positives zu true-negatives gestärkt werden. Zu beachten ist, dass hierdurch die Gesamtgröße der Trainingsdaten reduziert wird.
- **Normalisierung:** Obwohl unsere Eingabedaten bereits normalisiert sind, ist unter Umständen eine erneute Normalisierung der Features notwendig. Die extrahierten Features haben unterschiedliche Wertebereiche. Die Orientierungsfeatures können zum Beispiel Werte zwischen 0 und 360 annehmen. Die Distanzfeatures hingegen, liegen ungefähr im Bereich von 0 bis 1. Damit der Klassifikator dadurch nicht beeinträchtigt wird, ist es wichtig die Features durch erneute Normalisierung in einen einheitlichen Wertebereich zu projizieren.
- **Shufflen:** Um das Problem des Overfittings auf die Trainingsdaten zu reduzieren, werden diese, bevor sie in ein Trainings und Validierungsset aufgeteilt werden, zufällig durchgemischt. Dadurch enthalten beide Sets mit einer hohen Wahrscheinlichkeit Samples aus allen Videos.
- **PCA:** Da die Anzahl der extrahierten Features teilweise sehr hoch ist (zum Beispiel 2145 Features für die paarweise Extraktion alleine), ist es unter Umständen sinnvoll die Dimension der Features durch eine Principal Component Analysis (PCA) zu reduzieren. Dadurch wird die benötigte Trainingszeit zum Teil enorm verringert. Wir verwenden die PCA unter Erhaltung von 97% der Varianz.

Klassifikatoren

Wir nutzen zwei verschiedene Klassifikatoren. Zum einen eine Support Vektor Maschine (SVM) und zum anderen einen Random Forest (RF). Diese können mit verschiedenen Parametern trainiert werden. Auch in diesem Fall sind die optimalen Parameter zuvor allerdings unbekannt, weshalb verschiedene Kombination dieser getestet werden müssen.

Für die SVM haben wir verschiedene Kernel Funktionen mit unterschiedlichen Werten für *degree* und θ angewandt:

- Lineares Kernel: $K(x_i, x_j) = x_i^T x_j$
- Polynomieller Kernel: $K(x_i, x_j) = (x_i^T x_j + \theta)^{\text{degree}}$
- Radial Basis Kernel: $K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2}$
- Sigmoid Kernel: $K(x_i, x_j) = \tanh(\gamma x_i^T x_j + \theta)$

Für den Random Forest haben wir die maximale Tiefe und die Anzahl der Bäume variiert.

Überblick

2.3. Evaluierungsmethoden

Die im vorherigen Abschnitt beschriebenen Methoden zur Feature Extraction, Verarbeitung und Klassifikation sollen in verschiedenen Kombinationen evaluiert werden. Der erste Datensatz aus 10 Personen wird dazu aufgeteilt in 60% Trainingsmenge und 40% Validierungsmenge. Hier ist die Entscheidung zu treffen, wie die Personen auf die Mengen aufgeteilt werden:

1. Erst die Frames durchmischen, dann aufteilen: Dies ist sinnvoll, wenn der Klassifikator nur verwendet werden soll, um Action Units in neuen Frames von schon bekannten Personen zu erkennen. Es wird nicht getestet, wie gut der Klassifikator auf neue Personen generalisiert!
2. 6 Personen nur im Training, 4 nur in der Validierung verwenden: Die Performance auf der Validierungsmenge ist repräsentativ dafür, wie gut der Klassifikator Action Units bei bisher unbekannten Personen erkennt

Erste Tests haben gezeigt, dass Methode 1 zu deutlich besserem Performancestatistiken führt. Wir haben uns aber für Methode 2 entschieden, weil die Generalisierung auf neue Personen das interessantere Problem ist: In Anwendungsfällen ist es wünschenswert, für neue Personen nicht erst mehrere tausend Frames manuell labeln zu müssen, um den Klassifikator auf dieser Person zu trainieren.

Aufgrund der geringen Anzahl positiver Samples (Frames, in denen die Action Unit aktiviert ist), ist die Accuracy keine zuverlässige Statistik. Ein Klassifikator, der die Action Unit immer als "nicht aktiv" klassifiziert, könnte sehr hohe Accuracy erreichen, ohne tatsächlich etwas über die Action Unit gelernt zu haben. Stattdessen evaluieren wir die Klassifikatoren anhand von

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{F1 score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Der F1 score ist das harmonische Mittel zwischen Precision und Recall. Da wir von der Aufgabenstellung her keine Präferenz für hohe Precision / hohen Recall haben, nutzen wir den F1 score als erste Zahl zum Vergleich der Klassifikatoren.

Es werden alle Kombinationen aus Feature Extraction und Klassifikator mit verschiedenen Parametern auf dem ersten Datensatz trainiert und evaluiert. Anschließend werden die besten fünf pro Action Unit anhand des F1 scores ausgewählt. Da pro Action Unit ca. 160 Kombinationen evaluiert werden, kann es durch diese Auswahl der besten fünf zu einem Overfitting gegen die Validierungsmenge kommen. Um realistische Zahlen für die Performance zu bekommen, werden deshalb die besten fünf nochmal auf einer Testmenge evaluiert. Diese besteht aus fünf bisher unbekannten Personen aus einem zweiten Datensatz.




Abbildung 2.4.: Überblick über die Stationen des Trainings und der Klassifikation

3. Implementierung

Das Projekt wurde in C++ umgesetzt. Für die Erstellung einer Benutzeroberfläche wurde die QT5 Bibliothek verwendet [qt5]. Für verschiedene Algorithmen aus der Mustererkennung wurde die OpenCV2 Bibliothek genutzt [opencv]. Außerdem verwenden wir CMake als plattformunabhängiges Build-System [cmake]. Für das Projekt haben wir zwei separate Anwendungen erstellt, den QViewer und das Auto-Train Programm.

3.1. QViewer

Der QViewer ermöglicht uns die Visualisierung der Eingabedaten. Nachdem die Landmark und Action Unit Dateien geladen wurden, kann der Nutzer eines der Videos auswählen und abspielen. Zu jedem Frame zeigt der QViewer welche Action Units mit welcher Ausprägung aktiv sind 3.1

3.2. Auto-Train

Wie bereits in Kapitel 2 erwähnt, ist ein guter Klassifikator abhängig von der Wahl verschiedener Variablen, wie zum Beispiel von der Auswahl der Features oder von den Parametern mit denen der Klassifikator trainiert wird. Das Auto-Train Programm ermöglicht uns, automatisch verschiedene dieser Variablen auszuwählen, basierend darauf ein Klassifikator zu trainieren und an dem Validierungsset zu evaluieren. Die Resultate der Evaluation werden ebenfalls automatisch gespeichert. Die Konfiguration, das heisst eine Auswahl der Variablen die miteinander getestet werden sollen, kann aus einer einfach Json-Datei geladen werden ??.

Feature-Extractor

Um möglichst viele Kombinationen von einzelnen Features miteinander kombinieren zu können, haben wir eine Feature-Extractor-Aggregate Klasse erstellt, die es uns ermöglicht verschiedene Feature-Extractor aneinander zu koppeln und so kombinierte Features zu extrahieren. Kombiniert man beispielsweise die Extraktion der Orientierung zum Mittelpunkt, zusammen mit der Distanz zum Mittelpunkt, so erhält man pro Landmark zwei Features und damit pro Frame einen 132 elementigen Feature-Vektor 3.2.

- Zum trainieren und evaluieren
- Kurzes Wort zum Design von FeatureExtractor
- Automatisches Speichern aller relevanten Dateien.
- Erwähnung der JSON-Konfigurations-Datei
 - Design von Processors

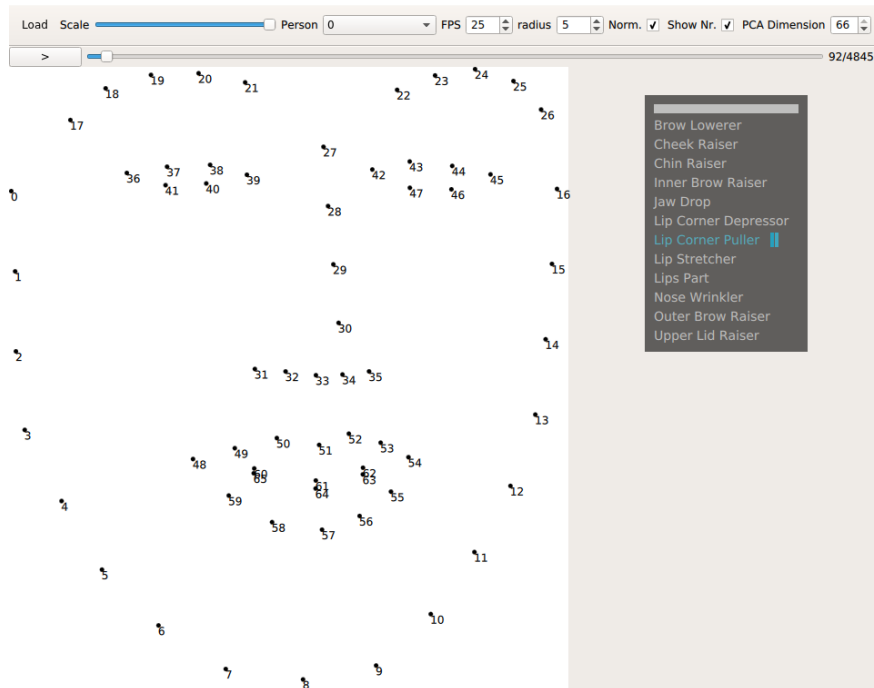


Abbildung 3.1.: Screenshot der QViewer Anwendung

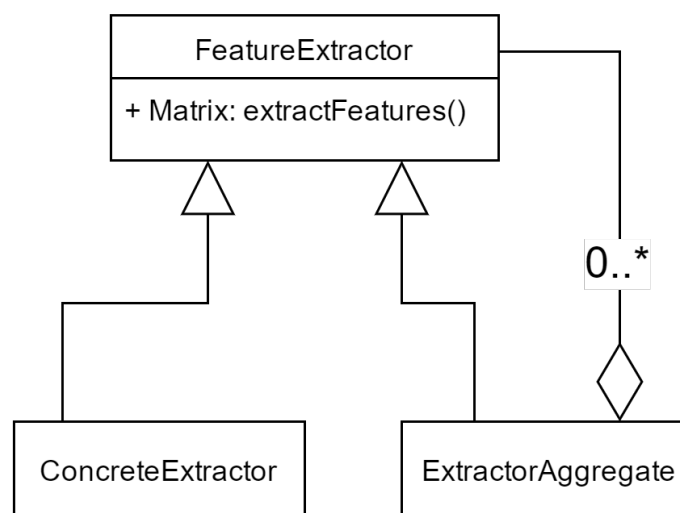


Abbildung 3.2.: UML-Diagramm der Feature-Extractor Klasse

4. Ergebnis

Bei den hier folgenden Ergebnissen, wurden die Videos durch Rauschen künstlich erweitert und normalisiert. Danach wurden die Features aus den resultierenden Landmarks extrahiert. Es folgte eine Normalisierung der Features anhand ihres Mittelwerts und ihrer Varianz. Für eine Reduktion des Feature-Raumes auf eine verbleibenden Varianz von 97% wurde dann der PCA-Algorithmus angewendet. Eine Ausnahme ist hierbei die Interpolation, da dieses Feature schon den Raum verkleinert hat, wurde auf eine weitere Reduktion durch PCA verzichtet. Schlussendlich wurden die Features dann zufällig geshuffled. Für zeitlichen Features haben wir uns nur auf X-/Y-Koordinaten und die Interpolationskoeffizienten konzentriert. Für die Ableitung wurde $\delta = 2$ gesetzt. Alle diese Methoden wurden in Kapitel 2 vorgestellt.

Wir haben dann anhand dieser Feature mehrere SVM mit den verschiedenen vorgestellten Kernelfunktionen trainiert. Zusätzlich haben wir auch verschiedene RF getestet, indem wir die Anzahl der Bäume und ihre maximale Tiefe variierten.

AU	Bester Klassifikator					Features
	F1 Val	F1 Test	Prec. Test	Recall Test	Klassifikator	
Lips Part	0.656	0.575	0.598	0.554	RF	CenterDist.
Upper Lid Raiser	0.394	–	0	0	SVM Polyn.	Interpolation
Outer Brow Raiser	0.391	–	0	0	SVM Polyn.	EuclidianDist.
Lip Corner Puller	0.37	0.431	0.317	0.674	SVM Lin.	XY
Cheek Raiser	0.277	0.18	0.102	0.769	SVM Polyn.	XY
Nose Wrinkler	0.242	0.03	0.015	0.62	SVM Polyn.	EuclidianDist.
Inner Brow Raiser	0.2	0.084	0.064	0.125	SVM Polyn.	EuclidianDist.
Chin Raiser	0.191	0.03	0.163	0.017	SVM Polyn.	CenterDist.
Brow Lowerer	0.163	0.2	0.659	0.118	RF	EuclidianDist.
Lip Corner Depressor	0.022	–	0	0	SVM Polyn.	XY

Tabelle 4.1.: F1 scores und Testergebnisse des besten Klassifikators pro Action Unit

In Tabelle 4.1 sind die Ergebnisse des besten Klassifikators (ausgewählt nach F1 score auf der Validierungsmenge) pro Action Unit zu sehen. Gute Klassifikation auf unbekannten Personen ist möglich für Lips Part: Der hohe F1 score 0.656 in der Validierung bestätigt sich auch auf der Testmenge. Akzeptable Performance liefert der beste Klassifikator für Lip Corner Puller. Dieser verbessert sich sogar von einem F1 score von 0.37 in der Validierung auf 0.431 im Test.

Die Klassifikatoren für Outer Brow Raiser und Upper Lid Raiser scheinen in der Validierung akzeptabel, erkennen jedoch im Test überhaupt keine Aktivierung der Action Units mehr. Die übrigen Action Units werden mit keiner unserer Feature Extraction-Methoden an neuen Personen befriedigend klassifiziert.

Abb. 4.1 zeigt, dass die verschiedenen Kombinationen aus Feature Extraction, Klassifikator und Parametern zu stark variierender Performance auf der Validierungsmenge führen. Der Tradeoff zwischen Precision und Recall ist deutlich zu sehen. Man sieht eine Trennung zwischen SVM und Random Forest Klassifikatoren: erstere tendieren dazu, zu viele negative Frames (ohne Aktivierung der Action Unit) als positiv zu klassifizieren, was zu schlechter Precision führt. Die Random Forests neigen hingegen zu vielen False Negatives. Sie schneiden




Abbildung 4.1.: Validierungsergebnisse für Lips Part und Lip Corner Puller. Jeder Punkt steht für eine Kombination aus Feature Extraction, Klassifikator und Parametern.

F1 Val	F1 Test	Prec. Test	Recall Test	Klassif.	Parameter	Features
0.656	0.575	0.598	0.554	RF	#trees = 20, maxDepth = 20	CenterDist.
0.656	0.594	0.639	0.555	RF	#trees = 50, maxDepth = 20	CenterDist.
0.647	0.655	0.809	0.550	RF	#trees = 20, maxDepth = 10	CenterDist.
0.623	0.616	0.966	0.452	RF	#trees = 50, maxDepth = 10	Interpolation
0.585	0.732	0.752	0.713	RF	#trees = 20, maxDepth = 20	XY

Tabelle 4.2.: F1 scores und Testergebnisse der Top 5 Klassifikatoren für Lips Part

bezogen auf Lips Part besser ab, bei anderen Action Units ist die Performance zwischen den Klassifikatoren ausgeglichen. Aus Platzgründen werden hier nur Graphen für ausgewählte Action Units gezeigt. Unsere gesamten Ergebnisse sind aber auf einer von uns erstellten Internetseite veröffentlicht¹.

Die Dominanz der Random Forests für Lips Part ist auch in Tabelle 4.3 zu sehen. Die beste SVM taucht mit einem F1 score von 0.356 in den Top 5 nicht mehr auf. Lip Corner Puller wird dagegen von einer SVM am besten erkannt, allerdings dominieren wieder Random Forests in den Top 5.

Schließlich liefert Tabelle 4.4 einen Vergleich der verschiedenen Features am Beispiel von Lips Part. Der Vergleichswert ist ein F1 score von 0.585, wenn man die Koordinaten aller Landmarks als Features übernimmt

¹web.

F1 Val	F1 Test	Prec. Test	Recall Test	Klassif.	Parameter	Features
0.370	0.431	0.317	0.674	SVM Lin.	–	XY
0.358	0.514	0.675	0.415	RF	#trees = 10, maxDepth = 4	Interpolation
0.347	0.389	0.752	0.262	RF	#trees = 50, maxDepth = 20	Interpolation
0.336	0.536	0.733	0.423	RF	#trees = 20, maxDepth = 10	Interpolation
0.248	0.426	0.774	0.293	RF	#trees = 20, maxDepth = 10	EuclidianDist.

Tabelle 4.3.: F1 scores und Testergebnisse der Top 5 Klassifikatoren für Lip Corner Puller

Features	Bester F1 score	Dimensionen	Dim. nach PCA
CenterDistance	0.656	66	17
Interpolation	0.623	37	–
XY	0.585	132	28
EuclidianDistance	0.5	2,145	30
Orientation	0.144	2,145	2,145
CenterOrientation	0.137	66	2
TimeDiff_XY	0.126	132	117
TimeDiff_Interpolation	0.06	37	–

Tabelle 4.4.: Vergleich der verschiedenen Features für Lips Part. Auf Interpolation-Features wurde keine PCA angewandt.

(“XY” in der Tabelle). Besser schneiden die Features “CenterDistance” und “Interpolation” ab. Es fällt auf, dass die PCA die Dimensionen von “Orientation” überhaupt nicht und von “CenterOrientation” fast vollständig reduziert. Die zeitbasierten Features bilden das Schlusslicht in den F1-Wertungen, mehr dazu in der Diskussion.

5. Diskussion

In den Ergebnissen haben wir gesehen, dass Lips Part und Lip Corner Puller relativ gut, die anderen Action Units eher schlecht erkannt werden. Lips Part ist leicht zu erkennen, da nur die Abstände der 6 Landmarks in der Mitte des Mundes relevant sind (vgl. Abb. 5.1) Dies erklärt auch, warum die eher




Abbildung 5.1.: Einfach Klassifikation von Lips Part

simple CenterDistanceExtraction erfolgreich ist: Ein Vergleich der Abstände von Landmarks 49 und 52 zum Mittelpunkt liefert ein einfaches Kriterium, ob die Action Unit aktiviert ist. In den Top 5 zu Lip Corner Puller taucht häufig die InterpolationExtraction auf. Wie in Abb. 2.2 dargestellt, kann durch Polynominterpolation gut die Form und Öffnungsrichtung von Ober- und Unterlippe extrahiert werden.

Eine weitere Erklärung in Bezug auf die Performanceunterschiede für verschiedene Action Units liefern Abb. 5.2 und Tabelle 5.2. Die Anzahl Frames, in denen die Action Unit aktiviert ist, variiert stark zwischen den Action Units. Nicht überraschend sind Lips Part und Lip Corner Puller in vergleichsweise vielen Frames aktiv. Upper Lid Raiser und Outer Brow Raiser lieferten zwar gute F1 scores in der Validierung, aber auf der Testmenge war die Performance schlecht (vgl. Tabelle 4.1). Auch dies stimmt mit einer geringen Anzahl positiver Frames überein. Möglicherweise wurde durch die Auswahl des besten Klassifikators aus 160 die Validierungsmenge overfitted.

Die Action Unit Brow Lowerer fällt hier aus der Reihe, da sie sehr schlecht klassifiziert wurde, obwohl viele positive Frames vorhanden waren. Wahrscheinlich haben wir hierfür nicht die richtigen Features gefunden.

AU	F1 Val	Positives in Training	
		#	%
Lips Part	0.656	12,516	21.5
Upper Lid Raiser	0.394	166	0.3
Outer Brow Raiser	0.391	2,712	4.7
Lip Corner Puller	0.37	6,454	11.1
Cheek Raiser	0.277	5,870	10.1
Nose Wrinkler	0.242	3,432	5.9
Inner Brow Raiser	0.2	3,522	6.1
Chin Raiser	0.191	2,104	3.6
Brow Lowerer	0.163	7,804	13.4
Lip Corner Depressor	0.022	350	0.6

Tabelle 5.1.: Gegenüberstellung der F1 scores und der Häufigkeit positiver Trainingsbeispiele




Abbildung 5.2.: F1 score des besten Klassifikators jeder Action Unit gegen Anteil positiver Frames

Die zeitbasierte Klassifikation war wenig erfolgreich. Auch hier ist ein Blick auf das Verhältnis positiver Frames aufschlussreich:

AU	Positives in Training	
	#	%
Lips Part	938	1.6
Brow Lowerer	584	1
Lip Corner Puller	536	0.9
Chin Raiser	434	0.7
Inner Brow Raiser	248	0.4
Outer Brow Raiser	200	0.3
Nose Wrinkler	196	0.3
Lip Corner Depressor	96	0.2
Upper Lid Raiser	80	0.1

Tabelle 5.2.: Positive Trainingsbeispiele für zeitbasierte Features

Aus den vorherigen Ergebnissen geht hervor, dass schon die Klassifikation der *aktuellen* Action Unit im Frame schwer ist. Deshalb ist es nicht verwunderlich, dass die Vorhersage, ob sich die Action Unit gerade ändert, noch schwerer zu treffen ist.

Insgesamt ist festzuhalten, dass die Generalisierung auf Personen, die nicht im Training gesehen wurden, eine schwierige Aufgabe ist. Wie Tabelle 5.3 zeigt, wurden während des Testlaufs für jede Action Unit mehrere Klassifikatoren gefunden, die auf dem Trainingsdatensatz fast perfekte Performance erreichen. Allerdings hat sich diese Performance nur in den wenigen bereits diskutierten Fällen auf die neuen Personen in Validierungs- und Testmenge übertragen. Die Klassifikatoren scheinen sich also die individuellen Formen und Abstände in den Gesichtern der Trainingspersonen gemerkt zu haben (Overfitting). Da RF im Allgemeinen resistenter gegenüber Overfitting ist, lässt sich auch seine Überlegenheit in dieser Arbeit damit erklären.

Es lässt sich schließen, dass die sechs Personen in der Trainingsmenge nicht genügend Varianz bieten, um den Klassifikator zur Abstraktion zu zwingen.

6. Fazit

6.1. Zusammenfassung

Die Aufgabe des Praktikums war es, Action Units in Gesichtern von Personen mittels der vorgegebenen Landmarks zu klassifizieren. Wir haben uns zusätzlich die Frage gestellt: Wie gut lässt sich ein Klassifikator trainieren, der Action Units bei unbekannten Personen erkennen kann?

Dazu haben wir uns sieben verschiedene Methoden überlegt, um aus den Landmarks aussagekräftige Features zu extrahieren. Diese reichen von eher simplen Features (Distanz zum Mittelpunkt), zu komplexeren wie die Polynominterpolation und die zeitliche Ableitung. Wir haben eine Pipeline gebaut, die es ermöglicht, viele Kombinationen aus Features, Klassifikationsalgorithmen und Parametern auf allen Action Units zu testen. Zur Evaluierung haben wir sinnvolle Performancestatistiken ausgesucht, die Klassifikatoren verglichen und die Ergebnisse visualisiert und diskutiert.

Wir stellen fest, dass die Verallgemeinerung auf im Training nicht gesehene Personen nur bei zwei Action Units befriedigend funktioniert hat. Dies liegt an der ungenügenden Anzahl verschiedener Personen in der Trainingsmenge sowie der geringen Anzahl von Frames, in denen manche Action Units aktiviert waren. Erfolgreich war die Erkennung von Lips Part und Lip Corner Puller. Hier haben auch die von uns entwickelten Features (Distanz zum Mittelpunkt bzw. Interpolation) gute Ergebnisse erzielt.

6.2. Ausblick

Wir wollen uns hier die Frage stellen, wie unser Ergebnis weiter verbessert werden könnte.

Um auch bei anderen Action Units bessere Ergebnisse zu erzielen, muss für größere Varianz in der Trainingsmenge gesorgt werden. Im Praktikum standen nur 15 Videos (davon nur 10 in der ersten Phase) zur Verfügung, was dazu geführt hat, dass in der Trainingsmenge nur sechs Personen vertreten waren. Die volle DISFA Datenbank bietet Videos von 27 Personen. Hier gibt es also mit mehr Daten noch Verbesserungspotential.

Im Praktikum wurden nur die Landmarks als Rohdaten benutzt. Allerdings enthalten die vollen Videos mehr Informationen, die sich mit Methoden der Computer Vision (Gabor Filter etc.) extrahieren ließen. Diese sind teilweise schon mit der DISFA mitgeliefert.

Die Klassifikation anhand von weiteren zeitbasierten Features könnte weiter ausgebaut werden. Dies ist aus Zeitgründen nicht geschehen. Allerdings müsste dazu die Einordnung eines Frames als aktiv bzw. nicht aktiv überdacht werden, damit es mehr positive Frames gibt.

Zusätzlich gibt es noch die Möglichkeit mehrere Features und Klassifikatoren zu kombinieren um verlässlichere Ergebnisse zu erzielen.

A. Anhang

A.1. Auflistung der relevanten Action Units

1. Inner Brow Raiser
2. Outer Brow Raiser
3. Brow Lowerer
4. Upper Lid Raiser
5. Cheek Raiser
6. Lid Tightener
7. Nose Wrinkler
8. Upper Lid Raiser
9. Nasolabial Fold Deepener
10. Lip Corner Puller
11. Cheek Puffer
12. Dimpler
13. Lip Corner Depressor
14. Lower Lip Depressor
15. Chin Raiser
16. Lip Puckerer
17. Lip Stretcher
18. Lip Funneler
19. Lip Tightner
20. Lip Pressor
21. Lips Part
22. Jaw Drop
23. Mouth Stretch
24. Lip Suc